

Biometria - Projekt 2

Katarzyna Skoczylas, Miłosz Zieliński

Kwiecień 2026

1 Wstęp

Celem projektu była implementacja systemu rozpoznawania tożsamości na podstawie obrazu tęczówki oka. Proces ten rozbito na kilka etapów: detekcję źrenicy i tęczówki, rozwinięcie obszaru tęczówki do postaci prostokąta, a następnie zastosowanie algorytmu Daugmana w celu wygenerowania kodu biometrycznego. Do oceny podobieństwa wzorców wykorzystano metrykę odległości Hamminga.

Projekt zrealizowano w języku Python, z wykorzystaniem bibliotek PIL oraz NumPy.

Kod źródłowy podzielono logicznie na dwie części:

- `iris.py` - plik zawierający implementację głównych klas i logikę matematyczną algorytmu.
- Notatniki Jupyter Notebook (2 pliki) - środowisko demonstracyjne, w którym zaprezentowano działanie poszczególnych etapów "krok po kroku" oraz przeprowadzono testy na zbiorze MMU Iris Dataset.

2 Segmentacja i normalizacja obrazu tęczówki

Proces przygotowania obrazu do ekstrakcji cech składa się z trzech głównych etapów: lokalizacji źrenicy, wyznaczenia zewnętrznej granicy tęczówki oraz normalizacji wyodrębnionego obszaru do układu biegunowego.

2.1 Lokalizacja środka i promienia źrenicy

Pierwszym krokiem jest odnalezienie środka źrenicy oraz jej promienia. Obraz wejściowy poddawany jest binaryzacji z progiem $T = \frac{P}{X_{pupil}}$, gdzie P to średnia jasność obrazu. Aby uzyskać spójną maskę obiektu i wyeliminować zakłócenia, stosowane są operacje morfologiczne otwarcia i zamknięcia.

Po ich zastosowaniu algorytm izoluje największy spójny obszar. Dla tak wyznaczonej maski obliczane są współrzędne środka (c_x, c_y) oraz promień r_p na podstawie analizy projekcji sumacyjnych wierszy i kolumn. Środek wyznaczany jest jako średnia z 50 % największych wartości, a promień na podstawie odległości między ekstremami pochodnej tego profilu.

2.2 Promień tęczówki

Wyznaczenie promienia tęczówki opiera się na zmodyfikowanym operatorze różniczkowo-całkowym Daugmana. Kluczowym elementem optymalizacji jest tu dynamiczne

wyznaczenie zakresu poszukiwań $[r_{min}, r_{max}]$. W tym celu wykorzystywany jest parametr X_{iris} , który służy do wygenerowania pomocniczej mapy binarnej ($T = \frac{P}{X_{iris}}$). Z mapy tej estymowany jest promień maksymalny r_{max} (jako 95. percentyl odległości pikseli obiektu od środka źrenicy). Zapobiega to błędnej detekcji krawędzi poza anatomicznym obszarem tęczówki i redukuje obciążenie obliczeniowe.

Właściwy promień tęczówki r_{iris} wyznaczany jest poprzez poszukiwanie maksimum funkcji:

$$r_{iris} = \arg \max_{r \in [r_{min}, r_{max}]} \left| G_{\sigma}(r) * \frac{\partial}{\partial r} \oint_{k(\theta)} I(r, \theta) d\theta \right|$$

gdzie $G_{\sigma}(r)$ to jednowymiarowy filtr Gaussa (w implementacji $\sigma = 5.0$) wygładzający szum. Aby zminimalizować wpływ powiek na wynik, całka konturowa pomija sektory θ odpowiadające obszarom pionowym (zakresy 75° – 105° oraz 255° – 285°).

2.3 Normalizacja obszaru tęczówki

W celu uniezależnienia procesu rozpoznawania od zmiennej wielkości źrenicy oraz różnej odległości oka od obiektywu, wysegmentowany obszar pierścieniowy przekształcany jest do znormalizowanego układu prostokątnego (model gumowej membrany Daugmana).

Proces mapowania pikseli z układu kartezjańskiego (x, y) na znormalizowany układ biegunowy (r, θ) opisany jest równaniami:

$$x(r, \theta) = c_x + r \cdot \cos(\theta)$$

$$y(r, \theta) = c_y + r \cdot \sin(\theta)$$

Gdzie promień r przyjmuje wartości z zakresu $[r_p, r_{iris}]$, a kąt $\theta \in [0, 2\pi)$.

Dzięki temu przekształceniu, struktura tęczówki zostaje "rozwinęta" do prostokątnej macierzy o wymiarach określonych przez zadaną rozdzielczość kątową i promieniową. Algorytm najpierw wyznacza dyskretne wartości kątów z zakresu $[0, 2\pi)$ oraz promieni z zakresu $[r_{inner}, r_{outer}]$. Następnie oblicza współrzędne mapowania przy wykorzystaniu funkcji trygonometrycznych. Po czym próbkuje obraz wejściowy i zapisuje wartości pikseli w nowej macierzy o wymiarach prostokątnych. Dzięki zastosowaniu wektoryzacji biblioteki `numpy`, proces ten jest efektywny obliczeniowo i pozwala na jednoczesne przetwarzanie wszystkich kanałów barwnych obrazu (RGB).

2.4 Algorytm Daugmana

Zaimplementowano klasę `IrisEncoder`, która zajmowała się całą logiką tworzenia kodu tęczówki na podstawie jej rozwinięcia do prostokąta.

- Podział prostokąta na osiem pasów
Oś Y prostokąta dzielona jest na 8 pasów. Gdy są to 64 wiersze daje nam to 8 pasów po 8 pikseli. Aby uniknąć włączania rzęs lub powiek do analizy pasma nie są brane w całości. Wybieranie fragmentów zaimplementowano zgodnie z materiałami udostępnionymi przez Prowadzącego. Pierwsze cztery pasy omijają 30-stopniowy sektor poniżej źrenicy (omijane kąty: 255-285). Kolejne dwa odcinki zawierają symetrycznie położone fragmenty o łącznej szerokości kątowej 226 stopni, ponieważ omijają one fragmenty po 67 stopni nad i pod źrenicą. Ostatnie dwa zewnętrzne pasy zostawiają tylko "czyste boki" po 90 stopni z każdej strony.
- Wybór 128 punktów na pasie i uśrednienie promienia w kierunku radialnym
Z racji tego, że silne korelacje między punktami występują na tym samym promieniu, a małe między punktami leżącymi na tym samym kącie wykonywane jest uśrednienie w

kierunku radialnym przy pomocy okna Gaussa. Dla każdego pasa wybierane jest 128 równoodległych punktów. Ostatecznie każdemu ze 128 punktów na pasku przyporządkowana jest 1 liczba.

- Falka Gabora

Falkę Gabora dla dziedziny dyskretnej zaimplementowano zgodnie ze wzorem:

$$G(n) = \exp\left(-\frac{n^2}{2\sigma^2}\right) \exp(-i2\pi fn)$$


gdzie f to częstotliwość falki, n to dyskretna współrzędna przestrzenna, a σ określa rozmycie obwiedni Gaussa.

Wartość σ uzależniono od zadanej długości filtra L zgodnie z zależnością $\sigma = \frac{L}{6}$. Takie podejście (oparte na regule trzech sigm) gwarantuje, że obwiednia Gaussa płynnie wygasa do wartości bliskich zeru na krańcach filtra, zapobiegając niepożądanym artefaktom na brzegach.

Na uśredniony pasek sygnału tęczówki nakładana jest falka Gabora, która wykrywa w nim lokalne cechy (zmiany fazy). Ostatnim etapem jest kwantyzacja (kodowanie) uzyskanych zespolonych współczynników fazowych do postaci dwubitowej.

3 Wyniki

3.1 Segmentacja tęczówki



Rysunek 1: Poszczególne etapy segmentacji tęczówki

Rysunek 1 przedstawia kolejne etapy przetwarzania przykładowego obrazu oka. Na obrazie binaryzacji widoczne są jasne obszary odpowiadające źrenicy oraz niewielkie artefakty w górnej części kadru (refleksy na skórze powiek), które zostają wyeliminowane przez operacje morfologiczne otwarcia i zamknięcia. Maskę źrenicy po morfologii ukazuje pojedynczy, regularny *blob* z którego wyznaczany jest centroid stanowiący punkt startowy dla operatora IDO.

Maska tęczówki przyjmuje postać pierścienia ograniczonego od wewnątrz przez granicę źrenica–tęczówka (czerwony okrąg, r_p) i od zewnątrz przez granicę tęczówka–twardówka (zielony okrąg, r_i). Na obrazie detekcji okręgów widać, że oba okręgi są współśrodkowe i precyzyjnie obejmują pierścień tęczówki. Rozwinięta tęczówka ukazuje charakterystyczną teksturę radialną w postaci poziomego prostokąta 64×360 pikseli.


3.2 Kod tęczęwki



Rysunek 2: Zakodowana tęczęwka

Rysunek 2 przedstawia przykładowy wygenerowany iris code. Wzorec jest niejednorodny i zawiera naprzemienne grupy zer i jedynek charakterystyczne dla poprawnej odpowiedzi filtru Gabora na teksturę tęczęwki. Widoczne pionowe struktury odpowiadają regularnym wzorom radialnym tęczęwki, natomiast poziome zróżnicowanie między pasami odzwierciedla zmianę tekstury wraz z głębokością radialną (od krawędzi źrenicy ku twardówce). Brak całkowicie czarnych lub całkowicie białych pasów potwierdza prawidłową pracę filtru. Ostatecznie jako częstotliwość nośną ustalono $f = 0,12$. Dawało to najlepsze rezultaty.

3.3 Macierz dystansów Hamminga



Rysunek 3: Macierz podobieństw tęczęwek

Rysunek 3 przedstawia symetryczną macierz 20×20 dystansów Hamminga dla zakodowanych przez nasze rozwiązanie zdjęć oczu 5 różnych, losowo wybranych osób (4 zdjęcia na każdą osobę). Wszystkie zdjęcia oczu pochodzą ze zbioru MMU Iris Dataset. Z analizy tej macierzy można wyciągnąć następujące wnioski:

- Porównania tęczyówek tej samej osoby
Wizualnie możemy wyróżnić diagonalne bloki w których wartości HD są w w zakresie 0,05–0,30, niższe od progu rozróżnienia $HD \approx 0,32$ [0]. Świadczy to o wysokiej powtarzalności kodów dla tej samej tęczyówki.
- Porównania między różnymi osobami
Bloki poza diagonalą, czyli porównania między różnymi osobami przyjmują wartości HD w przedziale 0,35–0,55, zbliżone do wartości oczekiwanej dla nieskorelowanych ciągów binarnych ($HD = 0,5$). Potwierdza to, że kody różnych osób są niezależne.
- Można zauważyć, że osoba Bryanl wskazuje niższe wyniki w przypadku niektórych porównań, jeżeli jednak spojrzymy na zdjęcia oczu tej osoby w pliku `tests.ipynb` to zobaczymy, że jedno z nich jest nienaturalnie ułożone. Biorąc pod uwagę losowość wyboru osób ze zbioru pojedyncze słabsze wyniki wydają się być zrozumiałe.

Ogólna separacja między rozkładem dystansów wewnątrzklasowych i międzyklasowych potwierdza poprawność zaimplementowanego algorytmu i jego zdolność do identyfikacji osób na podstawie tekstury tęczyówki.

4 Źródła

- https://pages.mini.pw.edu.pl/~rafalkoj/www/?Dydaktyka:2025%2F2026:-_Biometria
- Daugman, J. (2004). How Iris Recognition Works. IEEE Transactions on Circuits and Systems for Video Technology, 14(1), 21-30.